

# Lección 2

Marcos Bujosa

2 de noviembre de 2023

## Índice

<b>1. Precio de casas unifamiliares</b>	<b>2</b>
1.1. Actividad 1 - mostrar datos . . . . .	2
1.2. Actividad 2 - diagrama de dispersión . . . . .	2
1.3. Actividad 3 - Ajuste por MCO . . . . .	3
1.4. Actividad 4 - Recuperar los valores ajustados . . . . .	3
1.5. Actividad 5 - Otras formas de recuperar el ajuste . . . . .	3
<b>2. Plano de regresión</b>	<b>5</b>
<b>3. Simulación del ejemplo del precio de las viviendas con tres regresores</b>	<b>6</b>
3.1. Omisión de regresores . . . . .	7
3.2. Proyección omitiendo las constantes . . . . .	8
3.3. “Ortogonalizando” los regresores no constantes respecto de las constantes . . . . .	9
<b>4. Repetición del ejemplo pero introduciendo correlación entre regresores</b>	<b>11</b>
<b>5. Más sobre la ortogonalización de regresores</b>	<b>13</b>
5.1. Empleando regresores no constantes que son perpendiculares entre si . . . . .	13
5.1.1. Regresiones auxiliares . . . . .	13
5.1.2. Ajuste de P con los nuevos regresores . . . . .	14
5.2. Ajustes aún más curiosos . . . . .	14
5.2.1. Una primera proyección auxiliar . . . . .	14
5.2.2. Primer ajuste curioso . . . . .	14
5.2.3. Segundo ajuste curioso . . . . .	15

# 1. Precio de casas unifamiliares

Guión: [EjPvivienda.inp](#)

En esta primera práctica con [Gretl](#) reproduciremos el ejemplo visto repetidamente en clase. Los datos corresponden a los precios de venta y superficie útil de 14 casas unifamiliares en *University City*, San Diego, California. Año 1990. (Ramu Ramanathan, 2002)

Veremos como mostrar los datos, generar diagramas de dispersión, realizar un ajuste por MCO, y operar con series de datos y con parámetros estimados. Al final de la práctica aparece el guión completo con el código que evita trabajar con los menús en modo gráfico (que es el peor modo de trabajar con Gretl).

## 1. Objetivo

- a) Reproducir el primer ejemplo de regresión visto en clase.
- b) Mostrar datos.
- c) Generar gráficos.
- d) Guardar un modelo para poder consultarlo más tarde.
- e) Recuperar valores ajustados, errores estimados, etc.

## 2. Carga de datos *Archivo -->Abrir datos -->Archivo de muestra* y en la pestaña *Ramanathan* seleccione *data3-1*.

*o bien teclee en linea de comandos:*

```
open data3-1
```

### 1.1. Actividad 1 - mostrar datos

#### 1. Visualice los datos de precios y tamaños de las casas

- En la ventana principal de [Gretl](#), marque con el ratón ambas variables: **price**, **sqft**.
- “Pinche” sobre ellas con el botón derecho del ratón.
- Seleccione *mostrar valores* del menú desplegable que se ha abierto al pinchar.

*o bien teclee en linea de comandos:*

```
print -o price sqft
```

#### 2. Ayuda Para consultar la documentación sobre cualquier comando, puede emplear el menú desplegable *Ayuda* que aparece arriba, a la derecha de la ventana principal de [Gretl](#).

- *Ayuda ->Guía de Instrucciones* y “pinche” sobre *print*

*o bien teclee en linea de comandos: help print*

### 1.2. Actividad 2 - diagrama de dispersión

#### 1. Scatter plot

- Marque **price** y **sqft** (pulsando **ctrl** y pinchando con el botón derecho del ratón sobre ellas). Elija *Gráfico de dos variables XY*
- Seleccione **sqft** como variable del eje X

*o bien teclee en linea de comandos: gnuplot price sqft*

#### 2. Guardar gráfico como *icono* para editarlo más tarde

- “Pinche” con el botón derecho sobre la ventana del gráfico.

- Seleccione *Guardar a sesión como icono*

*o bien teclee en línea de comandos:*

```
RectaDeRegresion <- gnuplot price sqft
```

*(RectaDeRegresion es el nombre con el que se guardará el icono)*

En la zona inferior izquierda de la ventana principal puede ver una serie de iconos. Uno de ellos es la *vista de iconos de sesión*.

### 1.3. Actividad 3 - Ajuste por MCO

#### 1. Ajuste por MCO el modelo de regresión visto en clase

- Estime el modelo mediante los menús desplegables: *Modelo -> Mínimos Cuadrados Ordinarios*; indique a [Gretl](#) el regresando y los regresores y pulse *Aceptar*.

*o bien teclee en línea de comandos:*

```
ols price 0 sqft
```

*(el cero 0 indica el término constante: const)*

- “Pinche” *Archivo* en la ventana del modelo estimado y seleccione *guardar como un icono y cerrar*

*o bien teclee en línea de comandos:*

```
Regresion <- ols price 0 sqft
```

- Recupere el modelo “pinchando” sobre su icono

*o teclee en línea de comandos el nombre que ha dado al icono seguido de .show, es decir:*

```
Regresion.show
```

### 1.4. Actividad 4 - Recuperar los valores ajustados

#### 1. Recuperemos los valores ajustados

- Desde la ventana del modelo ajustado (recupérese con su icono), “pinche” en *guardar -> valores estimados*. Elija como nombre **phat** (puede añadir una descripción de la variable). Pulse en *Aceptar*

- Repita para guardar los **residuos** con el nombre **ehat**

*o bien teclee en línea de comandos:*

```
series phat = $yhat
series ehat = $uhat
```

#### 2. Mostremos las variables **price**, **sqft**, **phat** y **ehat**

- Marque las 4 variables (**ctrl** y “pinchar” con el botón derecho) y elija *mostrar valores*

*o bien teclee en línea de comandos:*

```
print -o price sqft phat ehat
```

### 1.5. Actividad 5 - Otras formas de recuperar el ajuste

- **phat2**: restar a los precios los errores

Desde la ventana del modelo: *Guardar -> Definir una nueva variable* y teclee: **phat2 = price - ehat**

*o bien teclee en línea de comandos:*

```
series phat2 = price - ehat
```

- **phat2**: Cálculo “chapucero”:  $52.351 + 0.139 \text{ sqft}$

*Guardar -> Definir una nueva variable* y teclee:

```
series phat3 = 52.351 + 0.139*sqft
```

- phat2: Cálculo correcto:  $\hat{\beta}_1 + \hat{\beta}_2 \text{ sqft}$   
*Guardar ->Definir una nueva variable y teclee:*

```
series phat4 = $coeff[1] + $coeff[2]*sqft
```

o bien:

```
series phat5 = $coeff(const) + $coeff(sqft)*sqft
```

- Visualice los valores como ya hizo en la Actividad 1 de más arriba. ¿Hay diferencias?  
*o bien teclee en linea de comandos:*

```
print -o price phat phat2 phat3 phat4
```

## Código completo de la práctica EjPvivienda.inp

```
open data3-1

print -o price sqft

RectaDeRegresion <- gnuplot price sqft

ols price 0 sqft

Regresion <- ols price 0 sqft

Regresion.show

series phat = $yhat
series ehat = $uhat

print -o price sqft phat ehat

series phat2 = price - ehat

series phat3 = 52.351 + 0.139*sqft

series phat4 = $coeff[1] + $coeff[2]*sqft

series phat5 = $coeff(const) + $coeff(sqft)*sqft

print -o price phat phat2 phat3 phat4
```

## 2. Plano de regresión

Guión: [PlanoRegresion.inp](#)

- Carga de datos. Abra los menús desplegables: *Archivo -->Abrir datos -->Archivo de muestra* y en la pestaña *POE 4th ed.* seleccione andy.

*o bien teclee en línea de comandos:*

```
open andy.gdt
```

- Ajuste por MCO las ventas a los precios y gastos en publicidad: *Modelo ->Mínimos Cuadrados Ordinarios*; indique a [Gretl](#) el regresando y los regresores y pulse *Aceptar*.

*o bien teclee en línea de comandos:*

```
ols sales 0 price advert
```

*(el cero 0 indica el término constante: const)*

- “Pinche” *Archivo* en la ventana del modelo estimado y seleccione *guardar como un icono y cerrar*

*o bien teclee en línea de comandos:*

```
Regresion <- ols sales 0 price advert
```

- Observe el *plano de regresión*: abra la ventana del modelo ajustado y pinche en *Gráficos ->Gráfico de variable estimada y observada ->Contra price y advert*

### Código completo de la práctica PlanoRegresion.inp

```
open andy.gdt

ols sales 0 price advert

Regresion <- ols sales 0 price advert

# solo es posible visualizar el plano de regresion con los menus desplegables
```

### 3. Simulación del ejemplo del precio de las viviendas con tres regresores

Guión: [SimuladorEjPvivienda.inp](#)

En este ejercicio con [Gretl](#) generaremos unos datos simulados para realizar regresiones MCO.

1. Simulamos series de datos de 500 observaciones

- *Archivo ->Nuevo conjunto de datos*, e indicamos el número de observaciones: 1500. Marcamos *de sección cruzada* y continuamos adelante. Dejamos sin marcar *empezar a introducir los valores de los datos* y pulsamos *Aceptar*.

- o bien:

```
nullldata 1500
```

2. Generamos tres variables: *S* con distribución uniforme (35, 120); *D* con distribución Chi cuadrado con 5 grados de libertad que vamos a multiplicar por 3 y *U* con distribución Normal de media 0 y desviación típica 40

- *Añadir ->Variable aleatoria* y se elige para cada variable el tipo de distribución, los valores de los parámetros y el nombre de la variable

- o bien

```
series S = randgen(U, 35, 120)
series D = randgen(X, 5) * 3
series U = randgen(N, 0, 40)
```

3. Simulamos los precios según el modelo  $p = 3001 + 5s - 2d + u$

- *Añadir ->Definir nueva variable* y tecleamos:  $P = 300 + 5*S - 2*D + U$

- O bien

```
series P = 300 + 5*S - 2*D + U
```

4. Observe los estadísticos de las variables de modelo. En particular, ¿son ortogonales *S* y *D* respecto al regresor constante **1**?

- *Ver ->Estadísticos principales* con el ratón marcamos *D*, *S* y *P*.

- O bien

```
summary P S D
```

5. El valor absoluto de la correlación entre *D* y *S* ¿es grande o pequeño?

- *Ver ->Matriz de correlación* y selecciones *D* y *S*.

- O bien

```
corr S D
```

6. Observe los diagramas de dispersión de *P* con *S*, el de *P* con *D*, y el de los regresores *S* y *D*:

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)*. Indicamos *S* como variable del eje x. Indicamos *P* como variable del eje y.

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)*. Indicamos *D* como variable del eje x. Indicamos *P* como variable del eje y.

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)*. Indicamos *S* como variable del eje x. Indicamos *D* como variable del eje y.

- O bien

```
scaterPS <- gnuplot P S
scaterPD <- gnuplot P D
scaterDS <- gnuplot D S
```

Nótese como dichos diagramas reflejan las correlaciones entre las distintas variables del modelo.

## 7. Ajuste por MCO P empleando S y D:

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios* y selecciones D y S.
  - Elija P como regresando o "variable dependiente"(marque la opción *Selección por defecto*).
  - Elija S y D como regresores o "Variables independientes". Pinche en *Aceptar*.
  - En la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
  - Con el botón derecho del ratón, pinche sobre el icono del modelo estimado y seleccione *Añadir a la tabla de modelos*.

- O bien

```
ModeloCompleto <- ols P 0 S D
modeltab add
```

Observe que el ajuste recupera aproximadamente los valores de los parámetros del modelo simulado.

Observe el *plano de regresión*: abra la ventana del modelo ajustado y pinche en *Gráficos ->Gráfico de variable estimada y observada ->Contra S y D*

- **Tarea adicional** Observe que el papel del parámetro  $\beta_1$  que acompaña al término constante es equilibrar los valores medios a ambos lados de la ecuación; es decir, asegurar que

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2\mu_S + \hat{\beta}_3\mu_D$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2\mu_S - \hat{\beta}_3\mu_D$$

- Hágalo empleando una calculadora o indique el cálculo en el guión de Gretl con

```
## TAREA ADICIONAL ####
scalar AjusteMediasC = mean(P) - $coeff(S)*mean(S) - $coeff(D)*mean(D)
scalar beta1HatC     = $coeff(const)
#####
```

Otra manera de aludir a los betas estimados es generar una matriz columna con los betas: `beta = $coeff`, de manera que `beta[1,1]`, `beta[2,1]` y `beta[3,1]` son  $\hat{\beta}_1$ ,  $\hat{\beta}_2$  y  $\hat{\beta}_3$  respectivamente.

## 3.1. Omisión de regresores

1. Si se omite el regresor D del ajuste ¿qué esperaríamos que ocurra con el parámetro asociado a la cte?

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*
  - En la lista de variables dependientes, pinche sobre D y pulse la flecha roja para eliminar dicha variable del modelo. Pinche en *Aceptar*.
  - la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
  - añada este modelo a la Tabla de modelos.

- O bien

```
ModeloSinD <- ols P 0 S
modeltab add
```

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Recuerde que el papel del parámetro  $\beta_1$  que acompaña al término constante es equilibrar los valores medios a ambos lados de la ecuación; en este caso,

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2 \mu_S$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2 \mu_S$$

- Hágalo empleando una calculadora o indique el cálculo en el guión de Gretl con  
## TAREA ADICIONAL ####  
scalar AjusteMediasNoD = mean(P) - \$coeff(S)\*mean(S)  
scalar beta1HatNoD = \$coeff(const)  
#####

2. Repita el experimento, pero esta vez incluyendo D y excluyendo S

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*
  - Elimine de la lista de regresores la variable S, e incluya D como regresor. Pinche en *Aceptar*.
  - la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
  - añada este modelo a la *Tabla de modelos*.
- O bien

```
ModeloSinS <- ols P 0 D  
modeltab add
```

donde `modeltab show` muestra la tabla de modelos ajustados.

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Aquí  $\beta_1$  asegura que

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2 \mu_D$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2 \mu_D$$

- Hágalo empleando una calculadora o indique el cálculo en el guión de Gretl con  
## TAREA ADICIONAL ####  
scalar AjusteMediasNoS = mean(P) - \$coeff(D)\*mean(D)  
scalar beta1HatNoD = \$coeff(const)  
#####

### 3.2. Proyección omitiendo las constantes

- ¿Y si calculamos la proyección ortogonal de los precios sobre S y D omitiendo la constante? ¿Qué espera que ocurra con los valores medios de P y del ajuste? Verifique su respuesta con el ordenador.
- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*
  - Elija S y D como regresores, pero elimine la constante de la lista (*¡algo que jamás debe hacer en sus estimaciones!*). Pinche en *Aceptar*.
  - la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
  - añada este modelo a la *Tabla de modelos*.
- O bien



```
ModeloSin1 <- ols P S D
modeltab add
```

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Aquí no hay un término constante, así que

$$\mu_P \neq \hat{\beta}_1 \mu_S + \hat{\beta}_2 \mu_D$$

El equilibrio se da añadiendo la media de los errores (que por no existir término constante es distinta de cero). Verifique que efectivamente

$$\mu_P = \hat{\beta}_1 \mu_S + \hat{\beta}_2 \mu_D + \mu_{\hat{e}}$$

- Hágalo empleando una calculadora o indique el cálculo en el guión de Gretl con

```
## TAREA ADICIONAL ####
scalar MediaLadoIzdo = mean(P)
scalar MediaLadoDcho = $coeff(S)*mean(S) + $coeff(D)*mean(D) + mean($uhat)
#####
donde $uhat son los residuos de la última regresión realizada.
```

Este ajuste sin constante, **y que por tanto no debemos llamar *regresión MCO***, no logra equiparar correctamente los valores medios de ambos lados de la ecuación. Los únicos elementos disponibles para intentar dicho ajuste han sido los vectores de datos **S** y **D**, que tienen medias distintas de cero. Pero simultáneamente dichos vectores son necesarios para lograr el ajuste de las pendientes. Por ello los resultados al omitir la constante pueden ser desastrosos.

### 3.3. “Ortogonalizando” los regresores no constantes respecto de las constantes

1. ¿Hay alguna forma de “ortogonalizar” **S** y **D** respecto de la constante?... ¡Si!, basta restar las medias (generar nuevos regresores en desviaciones respecto a su media):

- *Añadir ->Definir nueva variable* y escribimos series **S0** = **S** - mean(**S**)
- *Añadir ->Definir nueva variable* y escribimos series **D0** = **D** - mean(**D**)
- O bien

```
series S0 = S - mean(S)
series D0 = D - mean(D)
```

2. Verifique que la media de **S0** y **D0** es cero. Ajuste por MCO los siguientes modelos:

$$P = \beta_1 + \beta_2 S0 + \beta_3 D0$$

y

$$P = \beta_2 S0 + \beta_3 D0$$

Compare los resultados entre ambos y con el modelo completo original.

```
ModeloCompEnDesviaciones <- ols P 0 S0 D0
modeltab add
ModeloEnDesviaciones <- ols P S0 D0
modeltab add
modeltab show
```

- Compare la estimación de  $\beta_1$  del **ModeloCompEnDesviaciones** con la media de **P**.
- ¿Se le ocurre alguna explicación para este resultado?

- Observe en la tabla de modelos las similitudes del primer modelo en desviaciones con las obtenidas con el modelo completo original... ¡Todo es idéntico salvo la estimación de  $\beta_1$ !
- Observe que aunque las pendientes estimadas toman los mismos valores en ambos modelos en desviaciones, la incertidumbre asociada en el caso del modelo en desviaciones sin constante es mucho mayor

## Código completo de la práctica SimuladorEjPvivienda.inp

```

nullldata 1500

series S = randgen(U, 35, 120)
series D = randgen(X, 5) * 3
series U = randgen(N, 0, 40)

series P = 300 + 5*S - 2*D + U

summary P S D

corr S D

scaterPS <- gnuplot P S
scaterPD <- gnuplot P D
scaterDS <- gnuplot D S

ModeloCompleto <- ols P 0 S D
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasC = mean(P) - $coeff(S)*mean(S) - $coeff(D)*mean(D)
scalar beta1HatC     = $coeff(const)
#

ModeloSinD <- ols P 0 S
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasNoD = mean(P) - $coeff(S)*mean(S)
scalar beta1HatNoD = $coeff(const)
#

ModeloSinS <- ols P 0 D
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasNoS = mean(P) - $coeff(D)*mean(D)
scalar beta1HatNoD = $coeff(const)
#

ModeloSin1 <- ols P S D
modeltab add

# TAREA ADICIONAL
scalar MediaLadoIzdo = mean(P)
scalar MediaLadoDcho = $coeff(S)*mean(S) + $coeff(D)*mean(D) + mean($uhat)
#

series S0 = S - mean(S)
series D0 = D - mean(D)

ModeloCompEnDesviaciones <- ols P 0 S0 D0
modeltab add
ModeloEnDesviaciones <- ols P S0 D0
modeltab add
modeltab show

```

## 4. Repetición del ejemplo pero introduciendo correlación entre regresores

Guión: [SimuladorEjPvivienda2.inp](#)

En la simulación de la práctica anterior no había una correlación muy fuerte entre S y D. En ejemplos reales podemos encontrar una mayor riqueza de interrelaciones entre regresores. Para experimentar las consecuencias, vamos a repetir todo el ejercicio pero introduciendo un factor común entre S y D que genere correlación entre ambos regresores.

**Los datos** Vamos a variar el modo de generar los datos respecto a la práctica anterior.

- Genere un factor común C con distribución normal de esperanza 40 y desviación típica 20: *Añadir ->Definir nueva variable* y escribimos `series C = randgen(N, 40, 20)`
- Genere un vector de datos de superficies con distribución uniforme entre 20 y 70 y súmele C: *Añadir ->Definir nueva variable* y escribimos `series S = randgen(U, 20, 70) + C`
- Genere un vector de tiempos de viaje con distribución Chi cuadrado con 8 grados de libertad, y súmele 100 y réstele C: *Añadir ->Definir nueva variable* y escribimos `series D = randgen(X, 8) + 100 - C`
- Genere un vector de perturbaciones con distribución Normal de media 0 y desviación típica 40. *Añadir ->Definir nueva variable* y escribimos `series U = randgen(N, 0, 40)`
- O bien

```
nulldata 1500
series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)
```

**El modelo** que de nuevo simulamos es:  $p = 3001 + 5s - 2d + u$

- *Añadir ->Definir nueva variable* y tecleamos: `P = 300 + 5*S - 2*D + U`
- O bien

```
series P = 300 + 5*S - 2*D + U
```

**Actividades** Repita todas las actividades de la práctica anterior pero con estos nuevos datos simulados. Preste especial atención a cuáles son las diferencias entre esta simulación y la anterior sin correlación entre S y D.

Como ya están descritas en la práctica anterior, a continuación tan solo mostrare el guión modificado.

## Código completo de la práctica SimuladorEjPvivienda2.inp

```
nullldata 1500
series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)

series P = 300 + 5*S - 2*D + U

summary P S D

corr S D

scatterPS <- gnuplot P S
scatterPD <- gnuplot P D
scatterDS <- gnuplot D S

ModeloCompleto <- ols P 0 S D
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasC = mean(P) - $coeff(S)*mean(S) - $coeff(D)*mean(D)
scalar beta1HatC = $coeff(const)
#

ModeloSinD <- ols P 0 S
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasNoD = mean(P) - $coeff(S)*mean(S)
scalar beta1HatNoD = $coeff(const)
#

ModeloSinS <- ols P 0 D
modeltab add

# TAREA ADICIONAL
scalar AjusteMediasNoS = mean(P) - $coeff(D)*mean(D)
scalar beta1HatNoD = $coeff(const)
#

ModeloSin1 <- ols P S D
modeltab add

# TAREA ADICIONAL
scalar MediaLadoIzdo = mean(P)
scalar MediaLadoDcho = $coeff(S)*mean(S) + $coeff(D)*mean(D) + mean($uhat)
#

series S0 = S - mean(S)
series D0 = D - mean(D)

ModeloCompEnDesviaciones <- ols P 0 S0 D0
modeltab add
ModeloEnDesviaciones <- ols P S0 D0
modeltab add
modeltab show
```

## 5. Más sobre la ortogonalización de regresores

Guión: [SimuladorEjPvivienda3.inp](#)

En el ejemplo anterior hemos visto que al generar nuevos regresores  $S_0$  y  $P_0$  que son las componentes de  $S$  y  $P$  perpendiculares a las constantes, y usarlos en sustitución de los regresores originales, hemos logrado nuevos ajustes en los que incluir u omitir el regresor constante no cambia el valor de las pendientes estimadas.

### 5.1. Empleando regresores no constantes que son perpendiculares entre sí

Veamos si es posible generalizar este resultado, es decir, si al emplear como regresor la componente de  $S$  perpendicular a  $P$  y la constante, podemos ajustar  $P$  con tres regresores perpendiculares entre sí, de tal manera que omitir cualesquiera de los regresores no afecta a los parámetros estimados correspondientes a los regresores que sí se mantienen en el ajuste.

- Simulamos el modelo de la práctica anterior

```
nulldata 1500
series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)
series P = 300 + 5*S - 2*D + U
```

- Ajustamos los primeros tres modelos de la práctica anterior y los guardamos como iconos.

```
ModeloCompleto <- ols P 0 S D
modeltab add
ModeloSinD <- ols P 0 S
modeltab add
ModeloSinS <- ols P 0 D
modeltab add
ModeloSin1 <- ols P S D
modeltab add
```

- El último ajuste es una proyección ortogonal sin término constante (no una regresión). Calculemos el coeficiente de determinación y el coeficiente de determinación ajustado calculando explícitamente su fórmula.

```
# calculo del coeficiente de determinacion
scalar R2Sin1 = 1 - $ess/((T-1) * var(P))
scalar R2AjustadoSin1 = 1 - (T-1)/(T-2)*(1 - R2Sin1)
```

#### 5.1.1. Regresiones auxiliares

- Calculamos la componente de  $D$  que es ortogonal a los vectores constantes y la denominamos  $D_0$

```
# ortogonalizamos D respecto de las constantes
series D0 = D - mean(D)
# o de manera equivalente
ols D 0
series D0 = $uhat
```

- Calculamos la componente de  $S$  que es ortogonal a los vectores constantes y a  $D$  y la denominamos  $SpD$

```
# ortogonalizamos S respecto de las constantes y D
ols S 0 D
series SpD = $uhat
```

### 5.1.2. Ajuste de P con los nuevos regresores

- Mediante una regresión ajustamos por MCO P a los nuevos regresores

```
ModeloCompleto2 <- ols P 0 SpD D0
modeltab add
```

- Mediante una regresión ajustamos por MCO P únicamente al regresor constante

```
ModeloSolo1 <- ols P 0
modeltab add
```

- Mediante una proyección ajustamos P a SpD

```
ModeloSoloS <- ols P SpD
modeltab add
```

- Mediante una proyección ajustamos P a D0

```
ModeloSoloD <- ols P D0
modeltab add
```

- Compare los resultados de los distintos ajustes: los valores de los parámetros y el ajuste medido con el  $R^2$  corregido

```
modeltab show
```

## 5.2. Ajustes aún más curiosos

## Dos ajustes curiosos

En los siguientes ajustes lo que se mantiene es el valor del parámetro correspondiente la constante del modelo original (aunque no aparezca explícitamente ningún regresor constante en el ajuste... ahí radica la curiosidad).

### 5.2.1. Una primera proyección auxiliar

Lo primero es obtener la componente del vector **1** que es perpendicular a **S** y a **D** mediante una primera proyección auxiliar (no la llamaré regresión, pues el espacio sobre el que proyectamos no contiene los vectores constantes). Llamaré **cte** a dicha componente (pero obviamente no es un vector constante):

```
ols 0 S D # proyeccion del vector 1 sobre S y D
series cte = $uhat # componente del vector 1 que es perpendicular a S y a D
```

### 5.2.2. Primer ajuste curioso

En una nueva *proyección* auxiliar obtenemos la componente de **S** que es perpendicular a **cte** y a **D**, que llamaré **SpD** (componente de **S** perpendicular a **D** y a **cte**).

```
##### Primer ajuste curioso #####
```

```
ols S cte D
series SpD = $uhat # componente de S que es perpendicular a "cte" y a D
```

Y ahora realizamos la *regresión* de **P** sobre el mismo subespacio que en modelo original, pero empleando tres regresores que son ortogonales entre si, y tales que el parámetro de **cte** es igual al correspondiente a la constante del modelo original y el de **SpD** al del parámetro de **S** en la *proyección* de **P** sobre **S** y **D** (omitiendo la constante).

```
# regresion MCO que mantiene la pendiente de S del ajuste sin cte
ModeloCompletoAlternativo1 <- ols P cte SpD D
modeltab add
```

### 5.2.3. Segundo ajuste curioso

Alternativamente podemos dar los pasos análogos, pero usando la *proyección* auxiliar de D sobre cte y S.

```
##### Segundo ajuste curioso #####  
ols D cte S  
series DpS = $uhat      # componente de D que es perpendicular a cte y a S  
## regresion MCO que mantiene la pendiente de D del ajuste sin cte  
ModeloCompletoAlternativo2 <- ols P cte DpS S  
modeltab add  
modeltab show
```

Compare los resultados en la tabla de modelos.

## Código completo de la práctica SimuladorEjPvivienda3.inp

```
nulldata 1500
series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)
series P = 300 + 5*S - 2*D + U

ModeloCompleto <- ols P 0 S D
modeltab add
ModeloSinD <- ols P 0 S
modeltab add
ModeloSinS <- ols P 0 D
modeltab add
ModeloSin1 <- ols P S D
modeltab add

# calculo del coeficiente de determinacion
scalar R2Sin1 = 1 - $ess/(( $T-1) * var(P))
scalar R2AjustadoSin1 = 1 - ( $T-1)/( $T-2)*(1 - R2Sin1)

# ortogonalizamos D respecto de las constantes
series D0 = D - mean(D)
# o de manera equivalente
ols D 0
series D0 = $uhat

# ortogonalizamos S respecto de las constantes y D
ols S 0 D
series SpD = $uhat

ModeloCompleto2 <- ols P 0 SpD D0
modeltab add

ModeloSolo1 <- ols P 0
modeltab add

ModeloSoloS <- ols P SpD
modeltab add

ModeloSoloD <- ols P D0
modeltab add

modeltab show

# Dos ajustes curiosos

ols 0 S D # proyeccion del vector 1 sobre S y D
series cte = $uhat # componente del vector 1 que es perpendicular a S y a D

# Primer ajuste curioso
ols S cte D
series SpD = $uhat # componente de S que es perpendicular a cte y a D

# regresion MCO que mantiene la pendiente de S del ajuste sin cte
ModeloCompletoAlternativo1 <- ols P cte SpD D
modeltab add

# Segundo ajuste curioso
ols D cte S
series DpS = $uhat # componente de D que es perpendicular a cte y a S
# regresion MCO que mantiene la pendiente de D del ajuste sin cte
ModeloCompletoAlternativo2 <- ols P cte DpS S
modeltab add
modeltab show
```