

Lección 2

Marcos Bujosa

1 de octubre de 2023

Índice

1. Precio de casas unifamiliares	1
1.1. Actividad 1 - mostrar datos	2
1.2. Actividad 2 - diagrama de dispersión	2
1.3. Actividad 3 - Ajuste por MCO	2
1.4. Actividad 4 - Recuperar los valores ajustados	3
1.5. Actividad 5 - Otras formas de recuperar el ajuste	3
2. Plano de regresión	4
3. Simulación del ejemplo del precio de las viviendas con dos regresores.	5
3.1. Omisión de regresores	6
3.2. Proyección omitiendo las constantes	8
3.3. “Ortogonalizando” los regresores no constantes respecto de las constantes	8
4. Repetición del ejemplo pero introduciendo más correlación entre regresores	9
5. Más sobre la ortogonalización de regresores	11
5.1. Empleando regresores no constantes que son perpendiculares entre si	11
5.2. Ajustes aún más curiosos	12
5.2.1. Una primera proyección auxiliar	12
5.2.2. Primer ajuste curioso	12
5.2.3. Segundo ajuste curioso	12

1. Precio de casas unifamiliares

Guión: [EjPvivienda.inp](#)

En esta primera práctica con [Gretl](#) reproduciremos el ejemplo visto repetidamente en clase.

Los datos corresponden a los precios de venta y superficie útil de 14 casas unifamiliares en *University City*. San Diego, California. Año 1990. (Ramu Ramanathan, 2002)

Veremos como mostrar los datos, generar diagramas de dispersión, realizar un ajuste por MCO, y operar con series de datos y con parámetros estimados. Al final de la práctica aparece el guión completo con el código que evita trabajar con los menús en modo gráfico (que es el peor modo de trabajar con Gretl).

1. Objetivo

- Reproducir el primer ejemplo de regresión visto en clase.
- Mostrar datos.
- Generar gráficos.
- Guardar un modelo para poder consultarlo más tarde.
- Recuperar valores ajustados, errores estimados, etc.

2. Carga de datos *Archivo -->Abrir datos -->Archivo de muestra* y en la pestaña *Ramanathan* seleccione *data3-1*.

o bien teclee en línea de comandos:

```
open data3-1          # LEEMOS los datos
```

1.1. Actividad 1 - mostrar datos

1. Visualice los datos de precios y tamaños de las casas

- En la ventana principal de [Gretl](#), marque con el ratón ambas variables: *price*, *sqft*.
- “Pinche” sobre ellas con el botón derecho del ratón.
- Seleccione *mostrar valores* del menú desplegable que se ha abierto al pinchar.

o bien teclee en línea de comandos:

```
print -o price sqft    # MOSTRAMOS los datos
```

2. Ayuda Para consultar la documentación sobre cualquier comando, puede emplear el menú desplegable *Ayuda* que aparece arriba, a la derecha de la ventana principal de [Gretl](#).

- *Ayuda ->Guía de Instrucciones* y “pinche” sobre *print*

o bien teclee en línea de comandos: help print

1.2. Actividad 2 - diagrama de dispersión

1. Scatter plot

- Marque *price* y *sqft* (pulsando *ctrl* y pinchando con el botón derecho del ratón sobre ellas). Elija *Gráfico de dos variables XY*
- Seleccione *sqft* como variable del eje X

o bien teclee en línea de comandos: gnuplot price sqft

2. Guardar gráfico como *icono* para editarlo más tarde

- “Pinche” con el botón derecho sobre la ventana del gráfico.
- Seleccione *Guardar a sesión como icono*

o bien teclee en línea de comandos:

```
NombreDelGrafico <- gnuplot price sqft
```

(NombreDelGrafico es el nombre con el que se guardará el icono)

En la zona inferior izquierda de la ventana principal puede ver una serie de iconos. Uno de ellos es la *vista de iconos de sesión*.

1.3. Actividad 3 - Ajuste por MCO

1. Ajuste por MCO el modelo de regresión visto en clase

- Estime el modelo mediante los menús desplegables: *Modelo ->Mínimos Cuadrados Ordinarios*; indique a [Gretl](#) el regresando y los regresores y pulse *Aceptar*.

o bien teclee en línea de comandos:

```
ols price 0 sqft
```

(el cero 0 indica el término constante: const)

- “Pinche” *Archivo* en la ventana del modelo estimado y seleccione *guardar como un icono y cerrar* o bien teclee en línea de comandos:

```
Regresion <- ols price 0 sqft
```

- Recupere el modelo “pinchando” sobre su icono

o teclee en línea de comandos el nombre que ha dado al icono seguido de `.show`, es decir:

```
Regresion.show
```

1.4. Actividad 4 - Recuperar los valores ajustados

1. Recuperemos los valores ajustados

- Desde la ventana del modelo ajustado (recupérese con su icono), “pinche” en *guardar ->valores estimados*. Elija como nombre `phat` (puede añadir una descripción de la variable). Pulse en *Aceptar*
- Repita para guardar los **residuos** con el nombre `ehat`

o bien teclee en línea de comandos:

```
series phat = $yhat
series ehat = $uhat
```

2. Mostremos las variables `price`, `sqft`, `phat` y `ehat`

- Marque las 4 variables (`ctrl` y “pinchar” con el botón derecho) y elija *mostrar valores*

o bien teclee en línea de comandos:

```
print -o price sqft phat ehat
```

1.5. Actividad 5 - Otras formas de recuperar el ajuste

- `phat2`: restar a los precios los errores

Desde la ventana del modelo: *Guardar ->Definir una nueva variable* y teclee: `phat2 = price - ehat`

o bien teclee en línea de comandos:

```
series phat2 = price - ehat
```

- `phat2`: Cálculo “chapucero”: $52.351 + 0.139 \text{ sqft}$

Guardar ->Definir una nueva variable y teclee:

```
series phat3 = 52.351 + 0.139*sqft
```

- `phat2`: Cálculo correcto: $\hat{\beta}_1 + \hat{\beta}_2 \text{ sqft}$

Guardar ->Definir una nueva variable y teclee:

```
series phat4 = $coeff[1] + $coeff[2]*sqft
```

o bien

```
series phat5 = $coeff(const) + $coeff(sqft)*sqft
```

Visualice los valores ¿Hay diferencias?

```
print -o price phat phat2 phat3 phat4
```

2. Plano de regresión

Guión: [PlanoRegresion.inp](#)

- Carga de datos. Abra los menús desplegables: *Archivo -->Abrir datos -->Archivo de muestra* y en la pestaña *POE 4th ed.* seleccione *andy*.

o bien teclee en línea de comandos:

```
open andy.gdt
```

- Ajuste por MCO las ventas a los precios y gastos en publicidad: *Modelo ->Mínimos Cuadrados Ordinarios*; indique a [Gretl](#) el regresando y los regresores y pulse *Aceptar*.

o bien teclee en línea de comandos:

```
ols sales 0 price advert
```

(el cero 0 indica el término constante: const)

- “Pinche” *Archivo* en la ventana del modelo estimado y seleccione *guardar como un icono y cerrar*

o bien teclee en línea de comandos:

```
Regresion <- ols sales 0 price advert
```

- Observe el *plano de regresión*: abra la ventana del modelo ajustado y pinche en *Gráficos ->Gráfico de variable estimada y observada ->Contra price y advert*

3. Simulación del ejemplo del precio de las viviendas con dos regresores.

Guión: [SimuladorEjPvivienda.inp](#)

En este ejercicio [Gretl](#) generaremos unos datos simulados para realizar regresiones MCO.

1. Simulamos series de datos de 500 observaciones

- *Archivo ->Nuevo conjunto de datos*, e indicamos el número de

observaciones: 1500. Marcamos *de sección cruzada* y continuamos adelante. Dejamos sin marcar **empezar a introducir los valores de los datos** y pulsamos **Aceptar**.

- o bien:

```
nulldata 1500
```

2. Generamos tres variables: S con distribución uniforme (35, 120); D con distribución Chi cuadrado con 5 grados de libertad que vamos a multiplicar por 3 y U con distribución Normal de media 0 y desviación típica 40

- *Añadir ->Variable aleatoria* y se elige para cada variable el tipo de distribución, los valores de los parámetros y el nombre de la variable

- o bien

```
series S = randgen(U, 35, 120)
series D = randgen(X, 5) * 3
series U = randgen(N, 0, 40)
```

3. Simulamos los precios según el modelo $p = 3001 + 5s - 2d + u$

- *Añadir ->Definir nueva variable* y tecleamos: $P = 300 + 5*S - 2*D + U$

- O bien

```
series P = 300 + 5*S - 2*D + U
```

4. Observe los estadísticos de las variables de modelo. En particular, ¿son ortogonales S y D respecto al regresor constante 1?

- *Ver ->Estadísticos principales* con el ratón marcamos D, S y P.

- O bien

```
summary P S D
```

5. El valor absoluto de la correlación entre D y S ¿es grande o pequeño?

- *Ver ->Matriz de correlación* y selecciones D y S.

- O bien

```
corr S D
```

6. Observe los diagramas de dispersión de P con S, el de P con D, y el de los regresores S y D:

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)* y marcamos S como variable del eje x, y P como variable del eje y.

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)* y marcamos D como variable del eje x, y P como variable del eje y.

- *Ver ->Gráficos ->Gráfico X-Y (Scatter)* y marcamos S como variable del eje x, y D como variable del eje y.

- O bien

```
scaterPS <- gnuplot P S
scaterPD <- gnuplot P D
scaterDS <- gnuplot D S
```

Nótese como dichos diagramas reflejan las correlaciones entre las distintas variables del modelo.

7. Ajuste por MCO P empleando S y D:

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios* y selecciones D y S.
 - Elija P como regresando o "variable dependiente"(marque la opción **Selección por defecto**).
 - Elija S y D como regresores o "Variables independientes". Pinche en **Aceptar**.
 - En la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
 - Con el botón derecho del ratón, pinche sobre el icono del modelo estimado y seleccione **Añadir a la tabla de modelos**.
- O bien

```
ModeloCompleto <- ols P 0 S D
modeltab add
```

Observe cómo el ajuste recupera de manera muy aproximada los verdaderos valores de los parámetros del modelo simulado.

Observe el *plano de regresión*: abra la ventana del modelo ajustado y pinche en *Gráficos ->Gráfico de variable estimada y observada ->Contra S y D*

- **Tarea adicional** Observe que el papel del parámetro β_1 que acompaña al término constante es equilibrar los valores medios a ambos lados de la ecuación; es decir, asegurar que

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2\mu_S + \hat{\beta}_3\mu_D$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2\mu_S - \hat{\beta}_3\mu_D$$

- Hágalo empleando una calculadora
- O bien

```
## TAREA ADICIONAL ####
AjusteMediasC = mean(P) - $coeff(S)*mean(S) - $coeff(D)*mean(D)
beta1HatC      = $coeff(const)
#####
```

Otra manera de aludir a los betas estimados es generar una matriz columna con los betas: `beta = $coeff`, de manera que `beta[1,1]`, `beta[2,1]` y `beta[3,1]` son $\hat{\beta}_1$, $\hat{\beta}_2$ y $\hat{\beta}_3$ respectivamente.

3.1. Omisión de regresores

1. Si se omite el regresor D del ajuste ¿qué esperaríamos que ocurra con el parámetro asociado a la cte?

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*
 - En la lista de variables dependientes, pinche sobre D y pulse la flecha roja para eliminar dicha variable del modelo. Pinche en **Aceptar**.
 - la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.

- el botón derecho del ratón, pinche sobre el icono del modelo estimado y seleccione **Añadir a la tabla de modelos**.

- O bien

```
ModeloSinD <- ols P 0 S
modeltab add
```

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Recuerde que el papel del parámetro β_1 que acompaña al término constante es equilibrar los valores medios a ambos lados de la ecuación; en este caso,

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2 \mu_S$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2 \mu_S$$

- Hágalo empleando una calculadora
- O bien

```
## TAREA ADICIONAL ####
AjusteMediasNoD = mean(P) - $coeff(S)*mean(S)
beta1HatNoD = $coeff(const)
#####
```

2. Repita el experimento, pero esta vez incluyendo D y excluyendo S

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*

- Elimine de la lista de regresores la variable S, e incluya D como regresor. Pinche en **Aceptar**.
- la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
- el botón derecho del ratón, pinche sobre el icono del modelo estimado y seleccione **Añadir a la tabla de modelos**.

- O bien

```
ModeloSinS <- ols P 0 D
modeltab add
```

donde `modeltab show` muestra la tabla de modelos ajustados.

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Aquí β_1 asegura que

$$\mu_P = \hat{\beta}_1 + \hat{\beta}_2 \mu_D$$

Verifique que efectivamente

$$\hat{\beta}_1 = \mu_P - \hat{\beta}_2 \mu_D$$

- Hágalo empleando una calculadora
- O bien

```
## TAREA ADICIONAL ####
AjusteMediasNoS = mean(P) - $coeff(D)*mean(D)
beta1HatNoD = $coeff(const)
#####
```

3.2. Proyección omitiendo las constantes

- ¿Y si calculamos la proyección ortogonal de los precios sobre S y D omitiendo la constante? ¿Qué espera que ocurra con los valores medios de P y del ajuste? Verifique su respuesta con el ordenador.

- pinche en *Modelo ->Mínimos Cuadrados Ordinarios*
 - Elija S y D como regresores, pero elimine la constante de la lista (*¡algo que jamás debe hacer en sus estimaciones!*). Pinche en *Aceptar*.
 - la ventana del modelo pinche en *Archivo ->Guardar como icono y cerrar*.
 - el botón derecho del ratón, pinche sobre el icono del modelo estimado y seleccione **Añadir a la tabla de modelos**.
- O bien

```
ModeloSin1 <- ols P S D
modeltab add
```

¿Confirman los resultados lo esperado respecto a los parámetros estimados?

- **Tarea adicional** Aquí no hay un término constante, así que

$$\mu_P \neq \hat{\beta}_1 \mu_S + \hat{\beta}_2 \mu_D$$

El equilibrio se da añadiendo la media de los errores (que por no existir término constante es distinta de cero). Verifique que efectivamente

$$\mu_P = \hat{\beta}_1 \mu_S + \hat{\beta}_2 \mu_D + \mu_{\hat{e}}$$

- Hágalo empleando una calculadora
- O bien

```
## TAREA ADICIONAL ####
MediaLadoIzdo = mean(P)
MediaLadoDcho = $coeff(S)*mean(S) + $coeff(D)*mean(D) + mean($uhat)
#####
```

donde \$uhat son los residuos de la última regresión realizada.

Este ajuste sin constante (*y que por tanto no debemos llamar /regresión MCO/*p) no logra equiparar correctamente los valores medios de ambos lados de la ecuación. Los únicos elementos disponibles para intentar dicho ajuste han sido los vectores de datos S y D, que tienen medias distintas de cero. Pero simultáneamente dichos vectores son necesarios para lograr el ajuste de las pendientes. Por ello los resultados al omitir la constante pueden ser desastrosos.

3.3. “Ortogonalizando” los regresores no constantes respecto de las constantes

1. ¿Hay alguna forma de “ortogonalizar” S y D respecto de la constante?... ¡Si!, basta restar las medias (generar nuevos regresores en desviaciones respecto a su media):

- *Añadir ->Definir nueva variable* y escribimos series $S0 = S - \text{mean}(S)$
- *Añadir ->Definir nueva variable* y escribimos series $D0 = D - \text{mean}(D)$
- O bien

```
series S0 = S - mean(S)
series D0 = D - mean(D)
```

2. Verifique que la media de S0 y D0 es cero. Ajuste por MCO los siguientes modelos:

$$P = \beta_1 + \beta_2 S0 + \beta_3 D0$$

y

$$P = \beta_2 S_0 + \beta_3 D_0$$

Compare los resultados entre ambos y con el modelo completo original.

```
ModeloCompEnDesviaciones <- ols P 0 S0 D0
modeltab add
ModeloEnDesviaciones <- ols P S0 D0
modeltab add
modeltab show
```

- Compare la estimación del parámetro β_1 que acompaña al término constante en el primer caso con la media de P.
- ¿Se le ocurre alguna explicación para este resultado?
- Observe en la tabla de modelos todas las analogías en los resultados de estimación del primer modelo en desviaciones con las obtenidas con el modelo completo original. . . ¡Todo es idéntico salvo la estimación de β_1 !
- Observe que aunque las pendientes estimadas toman los mismos valores en ambos modelos en desviaciones, la incertidumbre asociada en el caso del modelo en desviaciones sin constante es mucho mayor

4. Repetición del ejemplo pero introduciendo más correlación entre regresores

Guión: [SimuladorEjPvivienda2.inp](#)

En la simulación de la práctica anterior no había una correlación muy fuerte entre S y D. En ejemplos reales podemos encontrar una mayor riqueza de interrelaciones entre regresores. Para experimentar las consecuencias, vamos a repetir todo el ejercicio pero introduciendo un factor común entre S y D que genere correlación entre ambos regresores.

Los datos

- Genere un factor común C con distribución normal de esperanza 40 y desviación típica 20: *Añadir ->Definir nueva variable* y escribimos `series C = randgen(N, 40, 20)`
- Genere un vector de datos de superficies con distribución uniforme entre 20 y 70 y súmele C: *Añadir ->Definir nueva variable* y escribimos `series S = randgen(U, 20, 70) + C`
- Genere un vector de tiempos de viaje con distribución Chi cuadrado con 8 grados de libertad, y súmele 100 y réstele C: *Añadir ->Definir nueva variable* y escribimos `series D = randgen(X, 8) + 100 - C`
- Genere un vector de perturbaciones con distribución Normal de media 0 y desviación típica 40. *Añadir ->Definir nueva variable* y escribimos `series U = randgen(N, 0, 40)`
- O bien

```
nulldata 1500
series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)
```

El modelo Simulamos los precios según el modelo $p = 3001 + 5s - 2d + u$

- *Añadir ->Definir nueva variable* y tecleamos: `P = 300 + 5*S - 2*D + U`
 - O bien
- ```
series P = 300 + 5*S - 2*D + U
```

**Actividades** Repita todas las actividades de la práctica anterior pero con estos nuevos datos simulados. Preste especial atención a cuáles son las diferencias entre esta simulación y la anterior sin correlación entre S y D.

```
summary P S D

corr S D

scaterPS <- gnuplot P S
scaterPD <- gnuplot P D
scaterDS <- gnuplot D S

ModeloCompleto <- ols P 0 S D
modeltab add

TAREA ADICIONAL
AjusteMediasC = mean(P) - $coeff(S)*mean(S) - $coeff(D)*mean(D)
beta1HatC = $coeff(const)
#####

ModeloSinD <- ols P 0 S
modeltab add

TAREA ADICIONAL
AjusteMediasNoD = mean(P) - $coeff(S)*mean(S)
beta1HatNoD = $coeff(const)
#####

ModeloSinS <- ols P 0 D
modeltab add

TAREA ADICIONAL
AjusteMediasNoS = mean(P) - $coeff(D)*mean(D)
beta1HatNoD = $coeff(const)
#####

ModeloSin1 <- ols P S D
modeltab add

TAREA ADICIONAL
MediaLadoIzdo = mean(P)
MediaLadoDcho = $coeff(S)*mean(S) + $coeff(D)*mean(D) + mean($uhat)
#####

series S0 = S - mean(S)
series D0 = D - mean(D)

ModeloCompEnDesviaciones <- ols P 0 S0 D0
modeltab add
ModeloEnDesviaciones <- ols P S0 D0
modeltab add
modeltab show
```

## 5. Más sobre la ortogonalización de regresores

Guión: [SimuladorEjPvivienda3.inp](#)

En el ejemplo anterior hemos visto que al generar nuevos regresores  $S_0$  y  $P_0$  que son las componentes de  $S$  y  $P$  perpendiculares a las constantes, y usarlos en sustitución de los regresores originales, hemos logrado nuevos ajustes en los que incluir u omitir el regresor constante no cambia el valor de las pendientes estimadas.

### 5.1. Empleando regresores no constantes que son perpendiculares entre sí

Veamos si es posible generalizar este resultado, es decir, si al emplear como regresor la componente de  $S$  perpendicular a  $P$  y la constante, podemos ajustar  $P$  con tres regresores perpendiculares entre sí, de tal manera que omitir cualesquiera de los regresores no afecta a los parámetros estimados correspondientes a los regresores que sí se mantienen en el ajuste.

```
nulldata 1500

series C = randgen(N, 40, 20)
series S = randgen(U, 20, 70) + C
series D = randgen(X, 8) + 100 - C
series U = randgen(N, 0, 40)

series P = 300 + 5*S - 2*D + U

ModeloCompleto <- ols P 0 S D
modeltab add

ModeloSinD <- ols P 0 S
modeltab add

ModeloSinS <- ols P 0 D
modeltab add

ModeloSin1 <- ols P S D
modeltab add

cálculo del coeficiente de determinación
R2Sin1 = 1 - $ess/((T-1) * var(P))
R2AjustadoSin1 = 1 - (T-1)/(T-2)*(1 - R2Sin1)

ortogonalizamos D respecto de las constantes
series D0 = D - mean(D)
o de manera equivalente
ols D 0
series D0 = $uhat

ortogonalizamos S respecto de las constantes y D
ols S 0 D
series SpD = $uhat

ModeloCompleto2 <- ols P 0 SpD D0
modeltab add
```

```
ModeloSolo1 <- ols P 0
modeltab add

ModeloSoloS <- ols P SpD
modeltab add

ModeloSoloD <- ols P D0
modeltab add
```

## 5.2. Ajustes aún más curiosos

## Dos ajustes curiosos

En los siguientes ajustes lo que se mantiene es el valor del parámetro correspondiente la constante del modelo original (aunque no aparezca explícitamente ningún regresor constante en el ajuste... ahí radica la curiosidad).

### 5.2.1. Una primera proyección auxiliar

Lo primero es obtener la componente del vector **1** que es perpendicular a **S** y a **D** mediante una primera proyección auxiliar (no la llamaré regresión, pues el espacio sobre el que proyectamos no contiene los vectores constantes). Llamaré a dicha componente **cte** (pero obviamente no es un vector constante):

```
ols 0 S D # proyección del vector 1 sobre S y D
series cte = $uhat # componente del vector 1 que es perpendicular a S y a D
```

### 5.2.2. Primer ajuste curioso

En una nueva *proyección* auxiliar obtenemos la componente de **S** que es perpendicular a **cte** y a **D**, que llamaré **SpD** (componente de **S** perpendicular a **D** y a **cte**).

```
Primer ajuste
ols S cte D
series SpD = $uhat # componente de S que es perpendicular a "cte" y a D
```

Y ahora realizamos la *regresión* de **P** sobre el mismo subespacio que en modelo original, pero empleando tres regresores que son ortogonales entre si, y tales que el parámetro de **cte** es igual al correspondiente a la constante del modelo original y el de **SpD** al del parámetro de **S** en la *proyección* de **P** sobre **S** y **D** (omitiendo la constante).

```
regresión MCO que mantiene la pendiente de S del ajuste sin cte
ModeloCompletoAlternativo1 <- ols P cte SpD D
modeltab add
```

### 5.2.3. Segundo ajuste curioso

Alternativamente podemos dar los pasos análogo, pero usando la *proyección* auxiliar de **D** sobre "ctez **S**".

```
Segundo ajuste
ols D cte S
series DpS = $uhat # componente de D que es perpendicular a cte y a S

regresión MCO que mantiene la pendiente de D del ajuste sin cte
ModeloCompletoAlternativo2 <- ols P cte DpS S
modeltab add
```

```
modeltab show
```

Compare los resultados en la tabla de modelos.